

传统机器学习方法在手写数字图像分类中的应用实验报告

学号：2022100270

姓名：史嘉仪

一、实验目的


- 1、理解图像如何转换为机器学习模型可以处理的特征向量；
- 2、掌握训练集和测试集的基本概念及其划分方法；
- 3、掌握常见传统机器学习分类方法（KNN、朴素贝叶斯、逻辑回归、SVM、决策树、随机森林）的基本使用；
- 4、比较不同分类器在同一图像分类任务中的表现差异；
- 5、学会使用准确率、混淆矩阵和错误样本分析评价分类结果。

二、数据集说明

项目	内容
数据集名称	sklearn 自带的 digits 手写数字数据集
图像大小	8 × 8 像素
图像类型	灰度图像（像素值范围 0-16）
样本数量	1797 张
类别数量	10 类（数字 0 到 9）
特征表示方式	将 8×8 的二维图像矩阵按行展开，得到 64 维特征向量

数据集样本分布（如图）：

- 训练集样本数：1347 张 (75.0%) 训练集特征矩阵形状：(1347, 64)
- 测试集样本数：450 张 (25.0%) 测试集特征矩阵形状：(450, 64)



三、实验方法

本次实验使用了以下六种传统机器学习分类方法：

方法	简要说明
KNN（K 近邻）	根据待分类样本在特征空间中最近的 K 个邻居的类别进行投票，得票最多的类别作为预测结果
朴素贝叶斯	基于贝叶斯定理，假设特征之间相互独立，计算样本属于每个类别的后验概率，选择概率最大的类别
逻辑回归	通过 Sigmoid 函数将线性回归的输出映射到 [0,1] 区间，学习分类决策边界，适用于二分类及多分类问题
支持向量机（SVM）	寻找一个最大间隔超平面将不同类别的样本分开，通过核函数可以处理非线性可分问题
决策树	通过递归地选择最优特征进行划分，构建树形结构，每个内部节点代表一个特征判断，叶节点代表分类结果
随机森林	集成学习方法，通过 Bootstrap 抽样构建多棵决策树，综合所有树的投票结果进行分类，降低过拟合风险

四、实验过程

4.1 数据准备与可视化

首先加载 sklearn 自带的 digits 数据集，查看数据基本信息：

【图像数量】

数据集共包含图像：1797 张

特征矩阵形状：(1797, 64) (样本数 x 特征数)

图像数组形状：(1797, 8, 8) (样本数 x 高 x 宽)

【图像大小】

每张图像尺寸：8 x 8 像素（灰度图）


展平后特征维度：64 维特征向量


【类别标签】

类别数量：10 类

标签列表：[0 1 2 3 4 5 6 7 8 9]

- 下图为部分样本图像及其真实标签的展示：





4.2 数据划分

- 将数据集按 75% / 25% 的比例划分为训练集和测试集：

数据集	样本数量	比例
训练集	1347	75%
测试集	450	25%

- 训练集和测试集的用途说明：


训练集（Training Set）：用于训练模型，让模型学习数据中的特征与标签之间的映射关系，是模型参数估计的依据。

测试集（Testing Set）：用于评估模型的泛化能力，即模型在未见过的数据上的表现。测试集不参与模型训练，能够客观反映模型的真实性能。

4.3 特征表示


特征转换方式：将每张 8×8 的灰度图像按行展开，得到一个长度为 64 的一维向量。例如，第一行 8 个像素值作为向量的第 1-8 个元素，第二行作为第 9-16 个元素，以此类推。

Pixel Visualization [True Label: 3]



为什么传统机器学习方法需要这种特征转换：传统机器学习算法通常期望输入是固定长度的一维特征向量，无法直接处理二维图像矩阵。将图像展平为向量后，可以方便地进行距离计算、内积运算等数学操作，满足算法的输入要求。

Task 3: Feature Representation



• 原始像素作为特征的优缺点与局限：

优点	局限
简单直观，无需复杂的特征工程	对图像平移、旋转、缩放非常敏感
保留了图像的原始像素信息	忽略了像素之间的空间结构关系

优点	局限
计算效率高，容易实现	维度灾难：高维特征需要大量训练样本
不依赖领域先验知识	缺乏局部不变性，微小变化会导致特征大幅改变


五、实验结果

5.1 不同模型准确率对比

模型	测试准确率	排名
KNN (k=5)	96.44%	3
朴素贝叶斯	76.44%	6
逻辑回归	97.78%	2
SVM	98.00%	1
决策树	82.67%	5
随机森林	96.22%	4

5.2 结果分析

Task 4 & 5: Model Training and Comparison



• 准确率最高的模型： SVM，测试准确率 98.00%

SVM 使用径向基核函数将数据映射到高维空间，能有效处理手写数字中像素间的非线性关系，同时 C=10 的正则化参数避免了过拟合，故表现最优。

• 准确率最低的模型： Naive Bayes，测试准确率 76.44%

朴素贝叶斯假设各特征相互独立，但像素特征之间存在强空间相关性（相邻像素高度相关），该假设明显不成立，导致性能相对较低。

• 不同模型之间的表现差异是否明显：差异较为明显，最高与最低相差 21.56 个百分点。集成方法（Random Forest）和核方法（SVM）明显优于单一线性/朴素方法；决策树与其他方法也有明显差距。

• 差异原因分析：产生差异的原因分析：

[模型容量] SVM/Random Forest 表达能力强，能学到复杂非线性边界；决策树、朴素贝叶斯容量有限或假设过强。

[特征利用] KNN 直接利用欧氏距离比较像素相似度,对 8x8 小图效果尚可；但对平移不鲁棒。


[独立性假设] 朴素贝叶斯要求特征条件独立，像素特征相关性强，假设被严重违反。

[集成效果] 随机森林通过 100 棵树的投票降低了单棵决策树的过拟合，准确率显著提升。



[数据规模] digits 数据集较小（1797 张），对 SVM 和逻辑回归有利；深度模型反而不适用。

5.3 混淆矩阵

以下为最佳模型（SVM）的混淆矩阵：



以下为最差模型（Naive Bayes）的混淆矩阵：



5.4 错误样本分析


从混淆矩阵可以看出，最容易混淆的数字对包括：

数字 2 和数字 8：被混淆次数 18 次

数字 3 和数字 8：被混淆次数 16 次

数字 2 和数字 1：被混淆次数 8 次

错误分类样本示例：



错误原因分析：

【Naive Bayes 最易混淆的数字对 Top-10】

真实 预测 次数 分析

2	-> 8	18 次	下弧结构相近
3	-> 8	16 次	底部闭环相似，易混
2	-> 1	8 次	笔画结构相近
8	-> 1	6 次	细长8与1视觉接近
4	-> 7	6 次	笔画结构相近
4	-> 1	6 次	笔画结构相近
9	-> 7	5 次	笔画结构相近
9	-> 1	4 次	笔画结构相近
9	-> 8	4 次	笔画结构相近
1	-> 6	3 次	笔画结构相近

六、实验总结

通过本次实验，我收获了以下认识和体会：

1. 传统机器学习方法处理图像的基本流程：

数据加载 → 数据预处理（展平为特征向量）→ 划分训练集/测试集 → 选择模型 → 训练模型 → 预测评估 → 结果分析

2. 不同分类器的优缺点对比：

模型	优点	缺点
KNN	简单直观，无需训练， 适合小数据集	预测速度慢，对特征缩放敏感， 维度灾难
朴素贝叶斯	计算效率高，对小样本	特征独立性假设通常不成

模型	优点	缺点
	数据表现好	立
逻辑回归	模型简单，可解释性强	只能处理线性可分问题
SVM	在小样本、高维数据上表现优秀，核函数可处理非线性问题	对参数和核函数选择敏感，训练时间较长
决策树	可解释性强，能处理非线性关系	容易过拟合，稳定性差
随机森林	泛化能力强，不易过拟合，能处理高维数据	模型复杂，可解释性差，训练时间较长

3. 使用原始像素作为特征的局限：

原始像素作为特征虽然简单直接，但缺乏对图像几何变换的不变性。当图像发生平移、旋转或缩放时，像素值向量会发生剧烈变化，导致模型无法正确识别。未来可以考虑使用 HOG、SIFT 等手工特征或深度学习自动提取特征来改善这一问题。

七、思考题

1. 为什么传统机器学习方法需要先把图像转换为特征向量？

传统机器学习算法的数学基础是向量空间模型，算法的输入通常被设计为固定长度的一维向量。例如，KNN 需要计算欧氏距离，SVM 需要计算向量内积，逻辑回归需要对特征进行线性组合。图像作为二维矩阵无法直接进行这些运算，因此需要展平为一维向量。

2. KNN、SVM、决策树和随机森林的分类思想有什么不同？

模型	分类思想
KNN	基于实例的学习，依靠邻居投票，没有显式的训练过程

模型	分类思想
SVM	基于几何间隔的学习，寻找最大化分类间隔的超平面
决策树	基于规则的学习，通过递归划分特征空间构建树形决策规则
随机森林	基于集成的学习，通过多棵决策树的投票进行决策，降低方差

3. 为什么单棵决策树容易过拟合？

单棵决策树在训练过程中会不断划分节点，直到所有叶子节点都尽可能纯净，这可能导致树变得非常深，学习了训练数据中的噪声和异常点。决策树对训练数据中的微小变化非常敏感，导致模型在训练集上表现很好但在测试集上表现较差。

4. 为什么随机森林通常比单棵决策树更稳定？

随机森林通过以下机制降低过拟合：

- **Bootstrap 采样**：每棵树使用不同的训练子集，增加树之间的差异性
- **随机特征选择**：每个节点分裂时只考虑部分特征，进一步增加多样性
- **集成投票**：多棵树的投票结果平均了单个树的偏差和方差，使模型更加稳定

5. 如果图像发生平移、旋转或缩放，直接使用原始像素作为特征会有什么问题？

平移问题：数字在图像中的位置变化会导致相同像素值出现在不同位置，特征向量完全改变

旋转问题：旋转后的图像像素分布与原始图像差异巨大，模型无法识别

缩放问题：缩放改变数字的粗细和形状，像素值分布随之改变

本质原因：原始像素特征是“绝对位置”编码，缺乏空间不变性，无法捕捉图像的局部结构信息